LAPORAN DATA SCIENCE COMPETITION
FIK FAIR 2026

Prediksi Anonymous Competition Score
dengan Eksplorasi Data dan Ansambel TabPFN

Tim Prikitiw

Muhammad Arif Ridho

Nathanael Komang Bagus Prakarsa

Abdul Azis

Keenan Gadi Palwono

UNIVERSITAS PEMBANGUNAN NASIONAL

"VETERAN" JAKARTA

2026

ABSTRAK

Panitia menyediakan 382 observasi berlabel dan 24 fitur anonim untuk memprediksi Anonymous Competition Score (ACS), indikator biaya hidup relatif, pada 96 observasi uji. Laporan ini menghubungkan eksplorasi data, keputusan eksperimen, hasil, dan batas interpretasinya. Data tidak memiliki nilai hilang, tetapi fitur berkorelasi dan target memiliki ekor kanan.

Enam komponen utama menjelaskan 95,59% variasi fitur, tetapi pengurangan komponen justru memperburuk validasi *ExtraTrees*. *Kernel Ridge* yang membaik secara lokal juga gagal pada papan peringkat publik. Pergantian ke TabPFN v2 menjadi titik balik: *mean fold* RMSE turun dari 8,4427 menjadi 7,6381. Diagnostik residual menunjukkan bahwa bias menurut target tidak cukup untuk membenarkan pelebaran prediksi secara global.

Resep publik terbaik menggabungkan tiga model fitur asli dan satu model fitur asli ditambah 12 komponen PCA, dengan bobot kelompok 50:50. Skor publik yang dilaporkan adalah 8,0391335665 pada 29 observasi; skor *private* belum diketahui. Berkas dan resep pembuatnya dapat ditelusuri, tetapi reproduksi keluaran FINAL secara identik belum terbukti. Implementasi yang tersedia berupa notebook dan inferensi *batch* dengan pemeriksaan CSV. Riwayat EXP-001–035 mencakup 25 entri registry dan sepuluh nomor dari catatan anggota, bukan 35 pengujian dengan protokol seragam.

Kata kunci: regresi, data anonim, eksplorasi data, TabPFN, PCA, validasi silang.

DAFTAR ISI

BAB I PENDAHULUAN 1
1.1 Latar belakang dan batas masalah 1
1.2 Tujuan dan ukuran keberhasilan 1
1.3 Ruang lingkup dan keterlacakan 1
BAB II ANALISIS DAN PEMBAHASAN 2
2.1 Data yang bersih tetap dapat sulit diprediksi 2
2.2 Apa yang membedakan ACS tinggi dan rendah? 3
2.3 Redundansi fitur dan jebakan persentase PCA 4
2.4 Membaca perbedaan train dan test secara hati-hati 5
2.5 Membedakan skor yang memang dapat dibandingkan 6
2.6 Titik balik: mengubah keluarga model 7
2.7 Ansambel terbaik publik dan batas bukti reproduksi 8
2.8 Bias menurut target belum menjadi aturan koreksi 9
2.9 Menilai manfaat tambahan sebelum tenggat 10
2.10 Hasil lokal dan ketidakpastian perbandingan 11
2.11 Skor publik adalah pembanding yang terbatas 12
2.12 Implementasi yang tersedia dan batas kesiapan 13
BAB III PENUTUP 14
3.1 Kesimpulan dan batas makna hasil 14
3.2 Dampak dan rekomendasi penggunaan 14
DAFTAR PUSTAKA 15
LAMPIRAN A RIWAYAT EKSPERIMEN DAN KEPUTUSAN 16
A.1 Ringkasan EXP-001 sampai EXP-007 16
A.2 Ringkasan EXP-008 sampai EXP-014 17
A.3 Ringkasan EXP-015 sampai EXP-021 17
A.4 Ringkasan EXP-022 sampai EXP-028 18

A.5 Ringkasan EXP-029 sampai EXP-035 18
A.6 Percobaan paralel dan bukti tambahan 19
LAMPIRAN B IDENTITAS ARTEFAK DAN REPRODUKSI 21
B.1 Identitas berkas publik terbaik 21
B.2 Informasi yang harus dipertahankan 21
B.3 Pemisahan status hasil 22
B.4 Tingkat verifikasi dan rekonsiliasi catatan 22
LAMPIRAN C SUMBER BUKTI DAN CATATAN VERIFIKASI ANGKA 23
LAMPIRAN D EDA FITUR DAN METRIK TERSIMPAN 24
D.1 Statistik deskriptif 24 fitur 24
D.2 Korelasi dan kelompok variabel 25
D.2.1 Korelasi seluruh fitur dengan target 26
D.3 RMSE, MAE, dan R^2 dari averaged OOF 27
LAMPIRAN E STATISTIK TARGET DAN DEFINISI ESTIMATOR 28

DAFTAR GAMBAR

Gambar 1 Distribusi target ACS 2

Gambar 2 Korelasi fitur dengan ACS 3

Gambar 3 Variasi kumulatif PCA 4

Gambar 4 Diagnostik kalibrasi OOF T3 9

Gambar 5 Perbandingan RMSE publik 12

Gambar 6 Alur implementasi inferensi batch 13

Gambar 7 Matriks korelasi fitur 25

DAFTAR TABEL

Tabel 1 Uji KS train dan test 5

Tabel 2 Definisi metrik evaluasi 6

Tabel 3 Komposisi ansambel FINAL 8

Tabel 4 Validasi lokal yang sejajar 11

Tabel A.1 Skor publik terpilih 16

Tabel C.1 Sumber bukti 23

Tabel D.1 Statistik 24 fitur 24

Tabel D.2 Korelasi fitur dengan target 26

Tabel D.3 Metrik averaged OOF 27

Tabel E.1 Statistik dan kuantil target 28

BAB I
PENDAHULUAN

1.1 Latar belakang dan batas masalah

Bayangkan sebuah daftar wilayah yang masing-masing digambarkan oleh 24 angka tanpa nama, tanpa peta, dan tanpa keterangan satuan. Tugas tim adalah memperkirakan wilayah mana yang biaya hidupnya relatif lebih tinggi. Itulah inti Data Science Competition FIK FAIR 2026: panitia menyediakan 382 observasi berlabel dan meminta prediksi ACS untuk 96 observasi tanpa label. ACS merepresentasikan biaya hidup relatif; nilai lebih tinggi menunjukkan biaya hidup relatif lebih tinggi.

Dua puluh empat fitur berasal dari variabel lingkungan dan iklim, tetapi nama asli, lokasi, sumber, dan proses transformasinya tidak dipublikasikan [1]. Konsekuensinya, analisis hanya dapat bersandar pada pola numerik dan kemampuan prediksi. Fitur anonim tidak diberi arti geografis atau hubungan sebab akibat yang belum diketahui.

Tantangan utamanya adalah memperoleh prediksi yang dapat digeneralisasikan dari sampel kecil. Tim menggunakan EDA untuk menyusun hipotesis, validasi untuk membandingkan kandidat, dan audit artefak untuk membatasi klaim hasil. Percobaan yang gagal tetap dipertahankan sebagai dasar pengambilan keputusan.

1.2 Tujuan dan ukuran keberhasilan

Laporan menjawab pola numerik apa yang relevan, perubahan model mana yang memberi manfaat konsisten, dan bagaimana menghasilkan prediksi yang dapat ditelusuri. RMSE menjadi metrik utama dan MAE menjadi pemecah seri. Penilaian publik memakai 29 observasi; penilaian *private* memakai 67 observasi [2].

Rubrik mencakup *insight* dan *storytelling* 30%, EDA 20%, visualisasi dan *dashboard* 20%, implementasi 20%, serta pemodelan 10% [3]. Karena itu, keberhasilan dinilai melalui hubungan temuan, keputusan, hasil, dan batas penerapan. Skor publik terbaik yang dilaporkan tim adalah 8,0391335665; skor *private* belum tersedia.

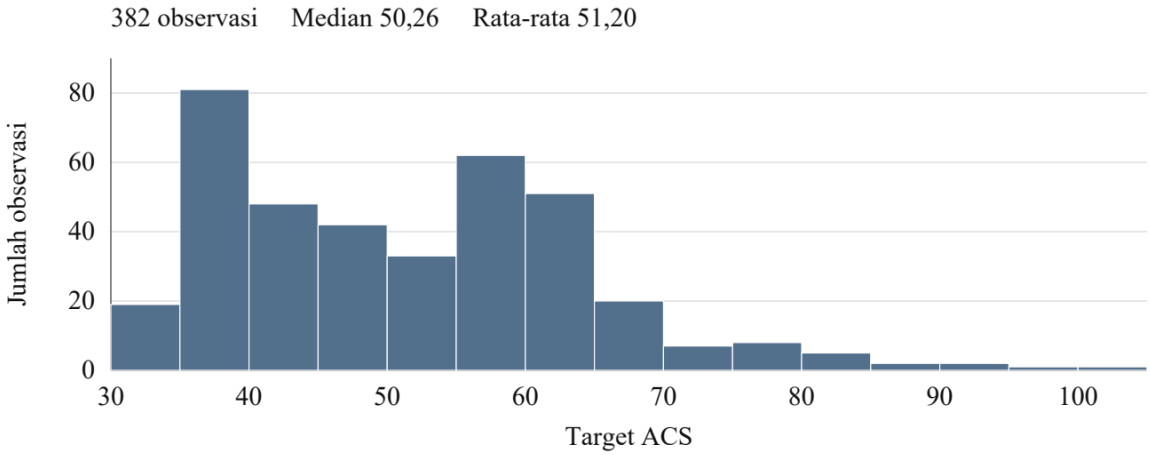
1.3 Ruang lingkup dan keterlacakan

Lampiran menelusuri EXP-001–035: 25 entri registry (EXP-001–010 dan EXP-021–035) dan sepuluh nomor dari catatan anggota (EXP-011–020). Penomoran ini bukan 35 pelatihan atau submission yang seragam.

BAB II
ANALISIS DAN PEMBAHASAN

2.1 Data yang bersih tetap dapat sulit diprediksi

Audit menemukan 382 baris *train*, 96 baris *test*, dan 24 fitur numerik. Tidak terdapat nilai hilang atau duplikasi vektor fitur pada gabungan data. record_id digunakan untuk penyelarasan keluaran, lalu dikeluarkan dari masukan model. Karena tidak ada alasan substantif untuk imputasi atau penghapusan, seluruh observasi dipertahankan (Lampiran C).



Gambar 1 Distribusi target ACS pada 382 observasi train

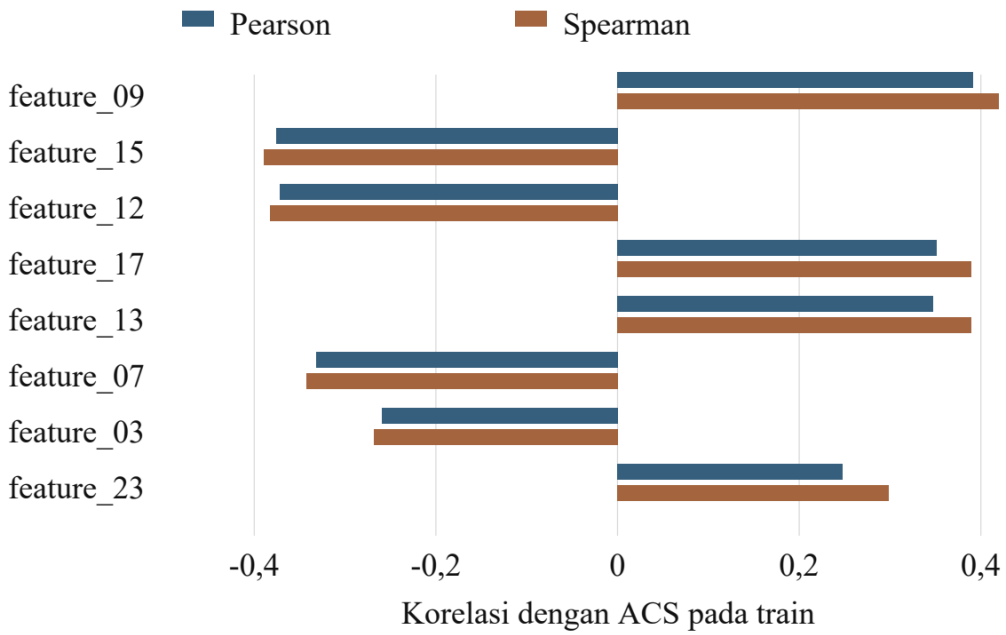
Gambar 1 menunjukkan ekor kanan dan dua puncak lokal pada histogram sekitar 35–40 dan 55–60. Bentuk puncak bergantung pada lebar bin; temuan ini belum membuktikan dua populasi atau segmen wilayah. Rata-rata target 51,2040, median 50,2565, dan simpangan baku 12,9060; rentangnya 32,5864–100,4400.

Skewness berbasis momen adalah +0,7484 dan *excess kurtosis* +0,5108, tanpa koreksi bias. P75 sebesar 60,1662 membagi lebar rentang bawah 27,5798 poin dan rentang atas 40,2737 poin. Sebanyak 286 dari 382 observasi berada di bawah atau sama dengan P75; statistik lengkap dan definisi rumus tersedia pada Lampiran E.

RMSE menguadratkan residual, sehingga kesalahan besar lebih berpengaruh, terlepas dari nilai targetnya. Tiga observasi melewati pagar atas 1,5 IQR sebesar 90,8827; ini penanda pemeriksaan, bukan bukti salah data. Titik tersebut tetap dipertahankan. Target di atas 100 juga menolak penggunaan 100 sebagai batas pemotongan otomatis.

2.2 Apa yang membedakan ACS tinggi dan rendah?

Fitur telah berada pada skala yang sebanding: rata-rata setiap fitur berkisar −0,0616 sampai +0,0503 dan simpangan baku 0,9714 sampai 1,0195. Seluruh fitur memiliki 382 nilai unik dan tidak tergolong hampir konstan. Kemencengan fitur berkisar −0,8905 sampai +0,8187; ekstrem fitur tidak dihapus hanya karena berada di ujung distribusi (Lampiran D.1).



Gambar 2 Delapan fitur dengan |Pearson| tertinggi terhadap ACS

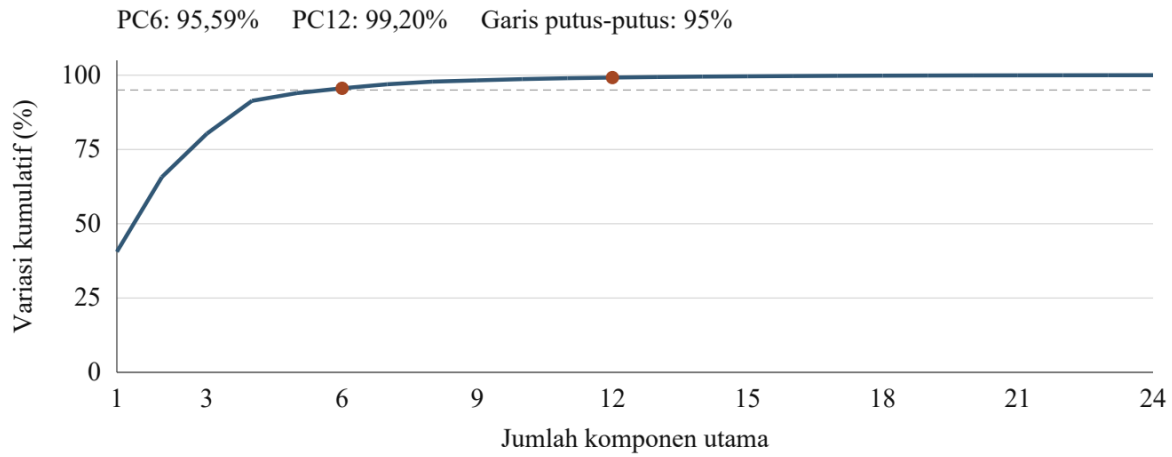
Gambar 2 membandingkan asosiasi linear (Pearson) dan peringkat (Spearman), bukan kepentingan model atau sebab akibat. feature_09 berkorelasi positif dengan ACS (Pearson +0,3911; Spearman +0,4199), sedangkan feature_15 (−0,3756; −0,3891) dan feature_12 (−0,3716; −0,3824) berkorelasi negatif. Arah yang sejalan pada kedua ukuran menunjukkan kecenderungan numerik yang relatif konsisten pada *train*.

Temuan ini memberi petunjuk kombinasi fitur yang perlu dipelajari model, tanpa menamai fitur sebagai faktor iklim tertentu. Korelasi satu fitur tetap sedang dan tidak merangkum hubungan nonlinear atau interaksi. Sebaliknya, feature_06 memiliki Pearson hanya +0,0127, tetapi muncul pada diagnosis kesalahan ekstrem EXP-009. Korelasi marginal yang kecil karena itu tidak cukup untuk membuang fitur.

Keputusannya adalah mempertahankan fitur asli dan menguji representasi alternatif secara terpisah. Profil semantik ACS tinggi dan rendah belum dapat dirumuskan karena arti fitur disembunyikan. Tabel seluruh korelasi disajikan pada Lampiran D.2.

2.3 Redundansi fitur dan jebakan persentase PCA

Terdapat 43 pasangan dengan |Pearson| ≥ 0,70; hitungan 50 pada arsip EDA memakai |Pearson| atau |Spearman| ≥ 0,70. Kelompok korelasi berukuran 4, 12, 2, 5, dan 1 fitur ditampilkan dalam matriks pada Lampiran D. Kelompok ini mengelompokkan variabel, bukan observasi atau wilayah. Redundansi belum berarti fitur dapat langsung dibuang.



Gambar 3 Variasi kumulatif fitur yang dijelaskan PCA pada EDA

Gambar 3 memperlihatkan bahwa enam komponen menjelaskan 95,59% variasi fitur dan 12 komponen menjelaskan 99,20% pada seluruh *train*. PCA mencari arah variasi masukan, bukan arah yang dioptimalkan terhadap target [5]. Persentase tersebut bergantung pada data dan *preprocessing*; statistik EDA ini tidak dipasang di luar *train fold* untuk evaluasi.

Hipotesis bahwa enam komponen cukup diuji pada EXP-026 dengan *ExtraTrees*. *Mean fold* RMSE memburuk dari 8,4427 menjadi 8,6669. Hasil ini menolak ambang 95% sebagai aturan seleksi otomatis pada konfigurasi tersebut, tetapi tidak membuktikan semua komponen minor selalu penting.

Cabang yang dipertahankan memakai 24 fitur asli ditambah 12 komponen, total 36 fitur. PCA menjadi representasi tambahan, sementara informasi fitur asli tetap tersedia. Keputusan ini mengikuti pengujian prediktif, bukan persentase variasi saja.

2.4 Membaca perbedaan train dan test secara hati-hati

Perbandingan distribusi dilakukan pada 24 fitur dengan uji Kolmogorov–Smirnov (KS), tanpa memakai target *test* atau mencari identitas wilayah. Karena pengujian dilakukan berulang pada banyak fitur, p-value juga dibaca setelah koreksi Benjamini–Hochberg (BH).

Tabel 1 Ringkasan uji KS antara train dan test

Pemeriksaan	Hasil	Interpretasi
Jumlah fitur yang diuji	24	Perbandingan distribusi marginal
$p < 0{,}05$ tanpa koreksi	9 fitur	Sinyal awal untuk pemeriksaan
$q < 0{,}05$ setelah BH	0 fitur	Belum ada bukti kuat setelah koreksi
Statistik KS terbesar	0,1907	Besarnya perbedaan empiris
q terkecil setelah BH	0,1000	Tidak melewati ambang 0,05

Sembilan fitur berbeda pada ambang $p < 0{,}05$ sebelum koreksi, tetapi tidak ada yang bertahan pada $q < 0{,}05$ setelah BH. Tidak signifikan bukan bukti bahwa distribusi identik; ukuran *test* yang kecil membatasi daya uji. Sebaliknya, sembilan hasil awal belum cukup untuk menyatakan pergeseran distribusi yang kuat (Lampiran C).

EXP-023 menunjukkan batas validasi lokal: *Kernel Ridge* dan blend-nya tampak membaik pada CV, tetapi skor publik menjadi 9,7606 dan 9,2409, lebih buruk daripada pembanding *ExtraTrees*. Perbedaan distribusi, sampel publik yang hanya 29 observasi, dan seleksi dari banyak percobaan adalah penjelasan yang mungkin; artefak belum membuktikan penyebab tunggal.

Temuan ini mengubah keputusan evaluasi. Kandidat dibandingkan pada pembagian yang sama, diperiksa per *repeat*, lalu kandidat terpilih diuji pada pembagian baru. Pemeriksaan *test* tetap bersifat diagnosis; transformasi yang mempelajari parameter dan pemilihan model menggunakan *train*.

2.5 Membedakan skor yang memang dapat dibandingkan

Protokol utama memakai *RepeatedKFold*: 10 *fold*, tiga *repeat*, *seed* pembagian 42. Setiap record memiliki tiga prediksi *out-of-fold* (OOF), sehingga tabel panjang berisi 1.146 pasangan target dan prediksi. *Seed* model mengatur variasi model; *seed* pembagian mengatur anggota *train* dan validasi. Keduanya dicatat terpisah.

Tabel 2 Definisi metrik evaluasi

Ukuran	Cara membaca
Mean fold RMSE	Rata-rata 30 nilai RMSE *fold*; setiap *fold* diberi bobot sama.
Pooled OOF RMSE	RMSE atas 1.146 pasangan target dan prediksi dari seluruh *repeat*.
Averaged OOF RMSE	Tiga prediksi per *record* dirata-ratakan dahulu, lalu RMSE dihitung pada 382 *record*.
RMSE publik	Penilaian panitia pada 29 *record test*; labelnya tidak tersedia bagi tim.

Merata-ratakan prediksi sebelum menghitung RMSE mengurangi variasi dengan cara yang berbeda dari merata-ratakan RMSE *fold*. Karena itu, ketiga ukuran lokal tidak dipertukarkan. Kandidat harus dibandingkan pada record, pembagian, metrik, dan lingkungan yang sama.

Scaler, PCA, dan transformasi lain dipasang hanya pada *train fold*, lalu diterapkan pada validasi [6]. Pemilihan bobot dari OOF yang sama tetap memiliki risiko bias seleksi. *Fold* berulang berbagi observasi sehingga 30 *fold* bukan 30 sampel independen; nilai p dan ukuran ketidakpastian harus dibaca dengan batas ini.

Pada EXP-034, pemeriksaan lanjutan memakai 10 *fold* dengan *seed* baru 20261011. Pembanding ikut dievaluasi pada pembagian baru tersebut. *Cache* hanya digunakan ulang bila konfigurasi, pembagian, ID record, dan versi artefak cocok; membaca ulang *cache* bukan eksperimen pelatihan baru.

2.6 Titik balik: mengubah keluarga model

Random Forest menetapkan baseline awal dengan *mean fold* RMSE 9,2841. *ExtraTrees* merata-ratakan banyak pohon dengan pemisahan acak; setelah penyetelan, *mean fold* menjadi 8,7088 dan skor publik 8,5018. Model ini menjadi pembanding awal yang kuat bagi hubungan nonlinear pada data kecil (EXP-004, Lampiran A).

Hipotesis berikutnya mencoba interaksi, subset fitur, transformasi target, dan pembobotan sampel. Hasil gagal memberi batas yang berguna: raw24 + lima interaksi memburuk menjadi 8,9659; transformasi akar menurunkan *mean fold* menjadi 8,6619 tetapi memperburuk bias target tinggi dari 6,9600 menjadi 7,3889. Penambahan PCA12 lebih menjanjikan, dengan *mean fold* 8,4427 dan skor publik 8,2578.

Titik balik terjadi saat keluarga model diganti. TabPFN merupakan model pralatih untuk data tabular yang belajar dari banyak tugas sintetis, kemudian menggunakan fitur dan target *train* untuk memprediksi observasi baru [4]. Aturan lokal memperbolehkan model pralatih sesuai batas kebijakan data eksternal [2]; penggunaannya di sini bukan pencarian identitas atau label wilayah.

Pada EXP-027, TabPFN v2 dengan 24 fitur asli menurunkan *mean fold* RMSE dari pembanding *ExtraTrees* 8,4427 menjadi 7,6381 dan menang pada 28 dari 30 *fold*. Pengujian *seed* 42, 17, dan 2026 diteruskan untuk memeriksa variasi model. Manfaat pergantian keluarga model lebih besar daripada perbaikan kecil yang diuji sebelumnya.

Keputusannya adalah menyusun ansambel dari model yang sudah memberi hasil baik, lalu menilai apakah kesalahannya saling melengkapi. Riwayat yang gagal tetap disimpan pada Lampiran A; angka dari protokol anggota yang berbeda tidak dianggap sebagai perbandingan berpasangan.

2.7 Ansambel terbaik publik dan batas bukti reproduksi

Resep dengan skor publik terbaik memakai TabPFN v2: tiga model *raw* dengan *seed* 42, 17, dan 2026, serta satu model *raw* + PCA12 dengan *seed* 42. Setiap model memakai n_estimators = 8, yaitu pengaturan internal TabPFN, bukan jumlah pohon *ExtraTrees*.

Tabel 3 Komposisi ansambel FINAL

Komponen	Masukan	Bobot akhir
Raw seed 42	24 fitur asli	1/6
Raw seed 17	24 fitur asli	1/6
Raw seed 2026	24 fitur asli	1/6
PCA *seed* 42	24 fitur asli + 12 PC	1/2

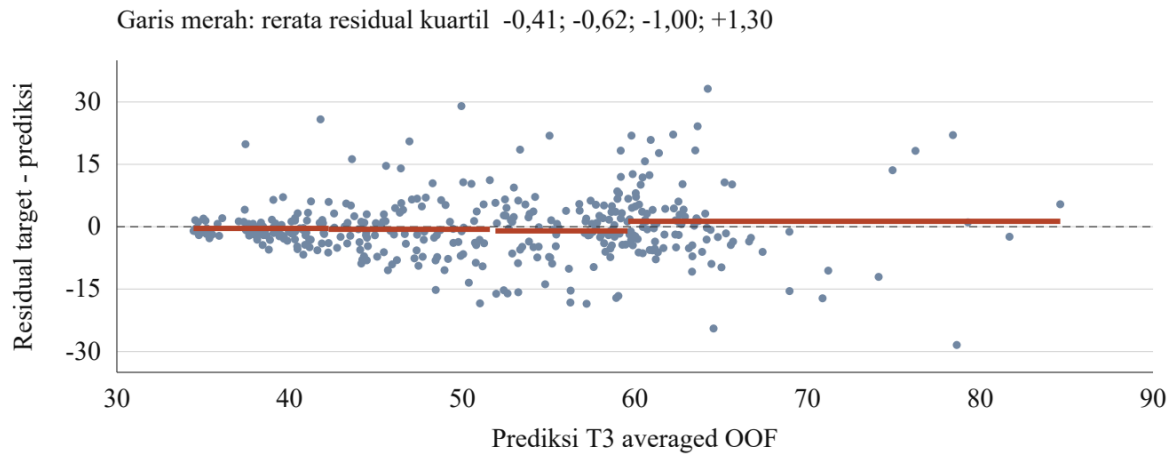
Prediksi akhir adalah 50% rata-rata tiga model *raw* ditambah 50% satu model *raw* + PCA12. Kode pembuat FINAL memasang PCA langsung pada fitur asli, tanpa *StandardScaler*, *solver* auto, dan tanpa *whitening*. C809 menggunakan *StandardScaler* sebelum PCA dengan *solver* full. Perbedaan tersebut membuat keduanya menjadi *pipeline* yang berbeda.

Audit membedakan tiga tingkat bukti. Berkas FINAL tersedia dan lolos pemeriksaan 96 ID unik, dua kolom, serta prediksi *finite*. Resep dapat ditelusuri ke sel pembuat FINAL dalam notebook anggota; keluaran tersimpan cocok pada jumlah, rata-rata, minimum, maksimum, dan contoh baris yang ditampilkan. Namun, kecocokan seluruh keluaran dari eksekusi ulang belum terbukti: tidak ada prediksi lengkap hasil *rerun* yang byte-identik dengan FINAL.

EXP-032 menghasilkan resep scaled dengan skor publik 8,0708363938. Perakitan ulang dari empat prediksi komponen yang tersimpan cocok dengan CSV EXP-032 hingga selisih maksimum $1{,}42 \times 10^{-14}$. Ini membuktikan perakitan bobot *cache* EXP-032, bukan reproduksi pelatihan baru atau identitasnya dengan FINAL. CSV, hash, konfigurasi, dan status bukti dirinci pada Lampiran B.

2.8 Bias menurut target belum menjadi aturan koreksi

Model awal cenderung terlalu tinggi pada target rendah dan terlalu rendah pada target tinggi. Akan tetapi, kelompok berdasarkan target asli tidak tersedia saat inferensi. Tim kemudian memeriksa residual target − prediksi menurut prediksi OOF T3, yaitu rata-rata tiga model *raw*, agar diagnosis menggunakan besaran yang tersedia saat penerapan.



Gambar 4 Diagnostik kalibrasi berdasarkan averaged OOF T3

Gambar 4 merangkum rata-rata residual kuartil prediksi sebesar −0,41; −0,62; −1,00; dan +1,30. Pada kuartil tertinggi (96 observasi), 47 diprediksi terlalu rendah dan 49 terlalu tinggi. Rata-rata yang relatif dekat nol menyembunyikan kesalahan individual besar; menaikkan seluruh kelompok akan membantu sebagian baris dan merugikan sebagian lainnya.

D0410 diprediksi sekitar 64,22 dengan target 97,38, sedangkan D0449 sekitar 64,55 dengan target 40,09. Kedua contoh hanya mengilustrasikan koreksi berlawanan, bukan uji formal ketidaklayakan kalibrasi. Sejalan dengan hasil kalibrasi awal yang belum meyakinkan, diagnosis ini belum memberi dasar untuk pelebaran rentang secara global.

Keputusannya adalah menunda koreksi global sampai manfaatnya terbukti pada validasi yang terpisah. Pola kuartil tidak membuktikan seluruh bentuk kalibrasi mustahil membantu; laporan juga tidak mengklaim slope atau interval kepercayaan yang belum dihitung.

2.9 Menilai manfaat tambahan sebelum tenggat

Menambah model tidak otomatis memperbaiki ansambel. Pada EXP-030, P3—rata-rata tiga *seed* cabang PCA—memiliki pooled RMSE 7,732440, lebih buruk daripada T3 *raw* sebesar 7,683114. Keragaman yang berguna ditentukan oleh kesalahan gabungan, bukan jumlah model.

RobustScaler pada EXP-033 memperbaiki rata-rata *fold*, tetapi *repeat* ketiga memburuk sekitar 0,0376 dan gagal toleransi 0,03. EDA terarah menunjukkan bahwa satu observasi menyumbang kenaikan *squared error* besar, sementara observasi lain sebagian mengimbangi. Temuan ini memicu pengujian stabilitas tanpa menghapus baris atau membuat koreksi khusus ID.

EXP-034 menggabungkan 50% T3, 25% cabang *StandardScaler*, dan 25% cabang *RobustScaler*. Pada pembagian baru, pooled RMSE membaik 0,020826 dengan enam *fold* menang dan empat kalah. Bukti ini mendukung kandidat lokal, tetapi skor publik 8,0704199627 belum mengalahkan FINAL. Rincian tahap A dan B tetap ada di Lampiran A.

EXP-035 menguji PCA tanpa *scaling* menggunakan artefak OOF yang sejajar, tanpa *fit* baru. Manfaat pooled hanya 0,003116; 15 *fold* menang dan 15 kalah, sedangkan MAE sedikit memburuk. Hasil ini gagal ambang promosi 0,02. Nilai p tercatat 0,7457 tidak membuktikan kesetaraan atau ketiadaan efek, terutama karena ketergantungan antarfold.

Dengan manfaat terakhir yang kecil dan tenggat dekat, tim mempertahankan acuan yang sudah ada dan beralih ke dokumentasi. Berhenti bukan pembuktian batas minimum RMSE, melainkan keputusan bahwa bukti untuk perubahan berikutnya belum cukup. Rekomendasi eksperimen baru harus memiliki hipotesis, pembanding, dan kriteria keberhasilan sebelum evaluasi.

2.10 Hasil lokal dan ketidakpastian perbandingan

Tabel 4 memakai artefak CPU sejajar pada pembagian utama. T3 adalah rata-rata *raw* tiga *seed*; P42 adalah *raw* + PCA12 scaled *seed* 42; P3 adalah rata-rata tiga *seed* cabang scaled. Baris terakhir memakai cabang PCA tanpa *scaling* dari audit EXP-035. Tabel ini membandingkan prediksi yang sepadan, bukan validasi persis *pipeline* GPU pembuat FINAL.

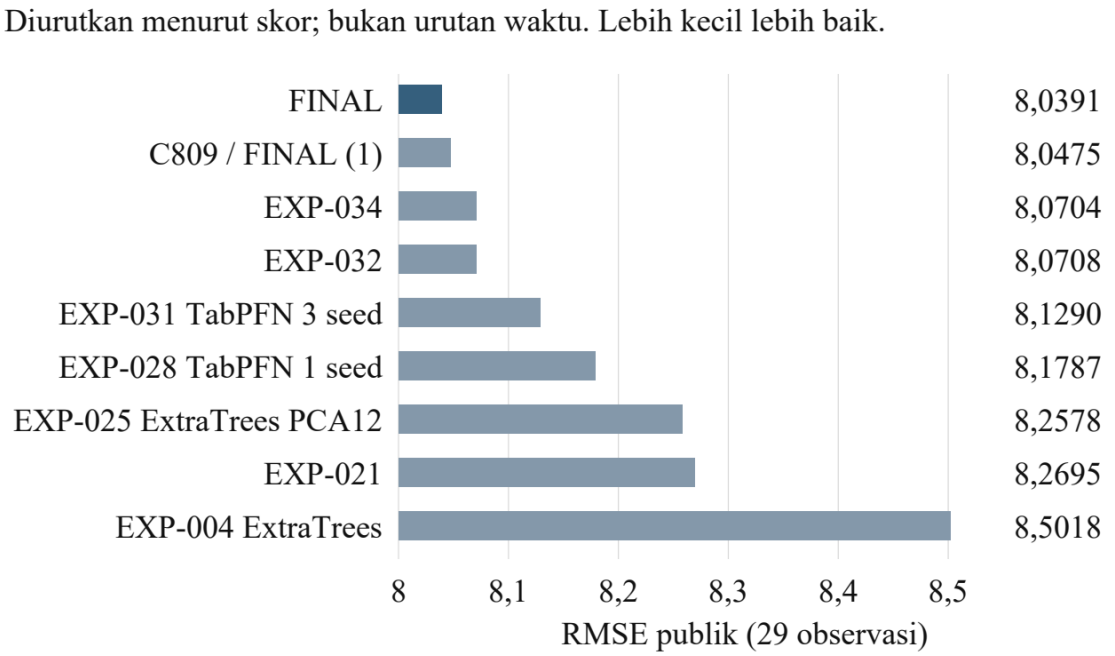
Tabel 4 Hasil lokal pada pembagian utama yang sama

Model	***Mean fold* RMSE**	***Pooled* RMSE**	**Avg OOF RMSE**
Raw seed 42	7,638113	7,729064	7,653869
T3 *raw*	7,590007	7,683114	7,612731
P42 *scaled*	7,636932	7,714311	7,637281
P3 *scaled*	7,652075	7,732440	7,659195
50% T3 + 50% P42	7,587419	7,671726	7,607629
50% T3 + 50% P3	7,596071	7,681902	7,618453
50% T3 + 50% PCA *raw*	7,585127	7,668610	7,604056

T3 memperbaiki model *raw* satu *seed*. Penambahan satu cabang PCA memberi manfaat kecil; tambahan *seed* PCA tidak melampauinya. Perbedaan antara scaled dan unscaled juga sangat kecil dan tidak memenuhi kriteria promosi. RMSE, MAE, dan R^2 *averaged OOF* dihitung ulang dari prediksi tersimpan pada Lampiran D.3, tanpa pelatihan baru.

Tahap B EXP-034 menghasilkan pooled RMSE baseline 7,506596 dan kandidat 7,485770. Angka ini berasal dari pembagian baru: bukti manfaatnya adalah selisih berpasangan −0,020826, bukan penurunan langsung dari 7,671726 pada Tabel 4. Penggunaan *train* yang sama dan banyak pemilihan adaptif tetap membatasi kepastian; pembagian baru bukan data eksternal independen.

2.11 Skor publik adalah pembanding yang terbatas



Gambar 5 Perbandingan submission terpilih menurut RMSE publik

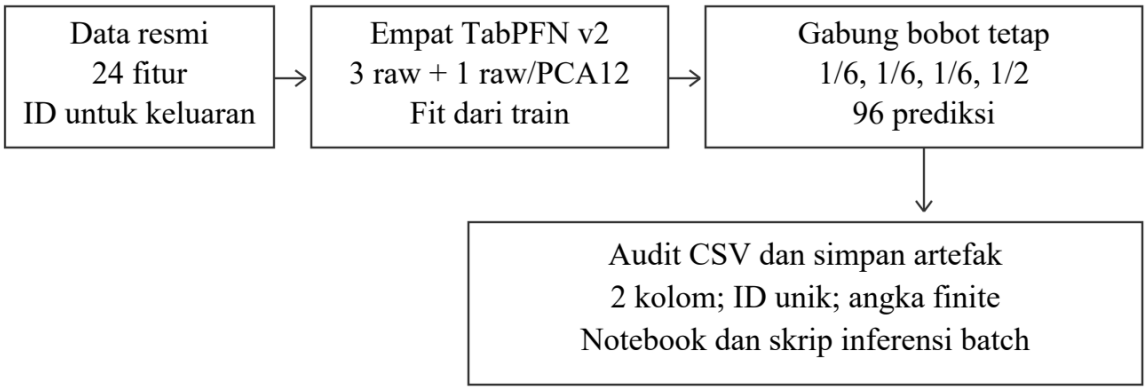
Gambar 5 diurutkan menurut skor. Sumbu bukan waktu dan tidak menyatakan satu lintasan eksperimen, sebab anggota tim mengembangkan beberapa jalur secara paralel. Fungsi visual ini adalah membandingkan besar capaian publik dan menunjukkan kecilnya selisih kandidat akhir; angka lengkap tersedia pada Tabel A.1.

Skor FINAL 8,0391335665 lebih rendah daripada C809 8,0475444831, tetapi selisih sekitar 0,0084 pada 29 observasi belum memastikan keunggulan pada 67 observasi *private*. C809 dan FINAL (1) identik byte demi byte, sehingga tidak dihitung sebagai dua bukti model independen. Korelasi C809 dengan FINAL adalah 0,999887, tetapi prediksinya tidak identik.

Rentang skor terpilih berkurang sekitar 0,463 dari *ExtraTrees* EXP-004 ke FINAL. Gambar ini tidak memisahkan pengaruh sebab akibat setiap perubahan. Bukti pergantian keluarga model berasal dari perbandingan CV yang sejajar, sementara perbandingan publik tetap merupakan hasil observasi pada subset kecil yang labelnya tidak diketahui.

Laporan mempertahankan tiga peran: FINAL sebagai pemilik skor publik terbaik yang dilaporkan; EXP-032 sebagai baseline pengembangan yang memiliki artefak komponen; dan EXP-034 sebagai kandidat lokal yang diuji pada pembagian baru. Skor publik tidak memberi bukti reproduksi atau jaminan generalisasi dengan sendirinya.

2.12 Implementasi yang tersedia dan batas kesiapan



Gambar 6 Alur inferensi batch yang tersedia dalam artefak tim

Gambar 6 menerangkan fungsi notebook dan skrip inferensi *batch* yang sudah tersedia: membaca data resmi, memilih fitur, memasang model pada *train*, memprediksi *test*, menggabungkan bobot tetap, lalu memeriksa dan menyimpan CSV. Empat model tidak memerlukan ID sebagai fitur; ID hanya menghubungkan prediksi dengan record *test*.

Artefak demonstrasi adalah notebook anggota beserta keluaran tersimpan, skrip final, notebook EXP-032, serta CSV prediksi dan komponen. Alur ini telah menghasilkan berkas dengan 96 baris dan dua kolom record_id/prediction. Pemeriksaan meliputi cakupan ID tepat satu kali dan nilai *finite*. Tidak ditemukan *dashboard* atau layanan web yang sudah dibuat; laporan tidak menambahkan klaim *deployment* maupun interval ketidakpastian yang belum divalidasi.

Untuk menjalankan *pipeline*, tim perlu menyiapkan *train*/*test* resmi, *checkpoint* yang sama, urutan fitur, konfigurasi, dan lingkungan yang sesuai; menjalankan sel pembuat yang tepat; lalu menyimpan prediksi komponen, CSV, versi perangkat lunak, serta checksum. Resep FINAL dan skrip scaled tidak dapat dipertukarkan. Detail langkah dan lingkungan ada di Lampiran B.

Kesiapan saat ini terbatas pada inferensi *batch* dalam kompetisi. Audit menemukan blok konfirmasi C809 yang tidak tercapai setelah *return*; skor *development* 60 split sebesar 7,700231 bukan hasil konfirmasi. Perbedaan CPU/GPU dan dependency juga membatasi reproduksi identik. Belum ada pengujian layanan operasional atau antarmuka bagi pengguna umum.

BAB III
PENUTUP

3.1 Kesimpulan dan batas makna hasil

Data bersih tidak otomatis mudah diprediksi. Korelasi antarfitur, ekor kanan target, dan sampel kecil menuntut validasi serta pembacaan residual yang hati-hati. Variasi PCA bukan ukuran informasi target; kegagalan *Kernel Ridge* memperlihatkan batas skor lokal; bias berdasarkan target belum cukup untuk membenarkan kalibrasi global. Temuan yang gagal membatasi pilihan, bukan dihapus dari cerita.

Pergantian *ExtraTrees* ke TabPFN memberi manfaat paling jelas pada evaluasi yang sebanding. Ansambel tiga model *raw* dan satu model *raw* + PCA12 menghasilkan skor publik terbaik yang dilaporkan, 8,0391335665. Berkas serta resepnya dapat ditelusuri, tetapi reproduksi keluaran FINAL secara identik dan skor *private* belum diketahui. Pembagian berulang, seleksi adaptif, dan perbedaan lingkungan membatasi kepastian hasil.

3.2 Dampak dan rekomendasi penggunaan

Dalam kompetisi, *pipeline* membantu tim dan evaluator membandingkan estimasi ACS pada record resmi, menilai ketepatan prediksi, dan menelusuri keputusan pengembangan. Skor dapat mendukung pemeringkatan relatif dalam konteks data yang diberikan. Karena fitur anonim dan wilayah tidak diketahui, hasil belum layak dijadikan dasar alokasi anggaran, penentuan biaya hidup wilayah nyata, atau klaim kausal mengenai lingkungan dan iklim.

Prioritas pertama adalah menjaga CSV terbaik, *checkpoint*, konfigurasi, keluaran komponen, dan lingkungan eksekusi. Evaluasi final mengikuti *private* leaderboard; klaim reproduksi baru dapat ditingkatkan jika hasil *rerun* seluruh record benar-benar cocok. Prediksi dan konfigurasi yang tersedia tidak boleh disamakan hanya karena nama atau skor publiknya berdekatan.

Untuk pengembangan di luar kompetisi, dibutuhkan arti fitur yang sah, tambahan data berlabel, evaluasi independen, serta uji manfaat bagi calon pengguna. *Dashboard* interaktif memerlukan pengembangan dan pengujian tersendiri; artefak tersebut belum tersedia. Eksperimen berikutnya sebaiknya menargetkan pola kesalahan yang dapat dikenali dari fitur saat inferensi, dengan kriteria promosi ditentukan sejak awal.

DAFTAR PUSTAKA

[1] Panitia FIK FAIR. (2026). Case Release Data Science Competition Dataset Specification. Dokumen resmi kompetisi.

[2] Panitia FIK FAIR. (2026). Competition Rules — FIK FAIR Data Science Competition. competition_rules.md, salinan proyek tim.

[3] Panitia FIK FAIR. (2026). Technical Meeting Data Science Competition. Materi ketentuan laporan dan bobot penilaian, PPT TM DSC FIK FAIR 2026.

[4] Hollmann, N., Müller, S., Purucker, L., et al. (2025). Accurate predictions on small data with a tabular foundation model. Nature, 637, 319–326. https://doi.org/10.1038/s41586-024-08328-6

[5] scikit-learn developers. (t.t.). Decomposing signals in components. Dokumentasi PCA. https://scikit-learn.org/stable/modules/decomposition.html

[6] scikit-learn developers. (t.t.). Common pitfalls and recommended practices. Dokumentasi pencegahan data leakage. https://scikit-learn.org/stable/common_pitfalls.html

Arsip internal bukan sumber teori eksternal. Nama berkas, tabel, kode, dan laporan eksperimen yang mendukung angka serta keputusan dirinci pada Lampiran C.

LAMPIRAN A RIWAYAT EKSPERIMEN DAN KEPUTUSAN

Lampiran ini menelusuri penomoran EXP-001–035: registry berisi 25 entri (EXP-001–010 dan EXP-021–035), sedangkan EXP-011–020 dirangkum dari catatan anggota dengan tingkat bukti berbeda. Tidak semua nomor adalah pelatihan baru atau submission. CV mengikuti protokol sumber dan tidak selalu dapat dipertukarkan. Percobaan paralel tidak dipaksakan menjadi satu urutan kausal. Tabel A.1 menyimpan skor publik yang dilaporkan tim.

Tabel A.1 RMSE publik pada *submission* atau tahap terpilih

Submission **atau tahap**	**RMSE publik**
EXP-004 ExtraTrees	8,5018233317
EXP-021 anggota tim	8,2695099413
EXP-025 *raw* + PCA12 ExtraTrees	8,2578077455
EXP-028 TabPFN *raw seed* 42	8,1787092844
EXP-031 rata-rata *raw* tiga *seed*	8,1290159832
EXP-032 *blend scaled* PCA	8,0708363938
EXP-034 *blend* Standard dan Robust	8,0704199627
C809 atau FINAL (1)	8,0475444831
FINAL dari *notebook* anggota tim	8,0391335665

A.1 Ringkasan EXP-001 sampai EXP-007

EXP-001 *Random Forest* sebagai baseline. *Mean fold* 9,2841; *averaged OOF* 9,2747; publik 9,4639. Menetapkan pembanding awal.

EXP-002 Menguji *ExtraTrees*. *Mean fold* 8,8244; *averaged OOF* 8,8157; publik 8,7753. Lanjutkan keluarga *ExtraTrees*.

EXP-003 Audit fitur dan residual. Memeriksa korelasi, perbedaan distribusi, dan kesalahan ekor. Menjadi dasar hipotesis berikutnya, bukan submission baru.

EXP-004 Tuning *ExtraTrees*. 100 estimator, max_features 0,75, leaf 1. *Mean fold* 8,7088; publik 8,5018. Benchmark utama awal.

EXP-005 Kuadrat, interaksi, dan clustering. Cluster sekitar 8,6952; kombinasi 8,7471 dan seluruh fitur 8,8499. Manfaat tidak stabil; tidak dipromosikan.

EXP-006 Transformasi target akar. *Mean fold* 8,6619, tetapi bias target tinggi memburuk dari 6,9600 menjadi 7,3889. Trade-off tidak diterima.

EXP-007 Pembobotan sampel. Alpha 0,25 memberi *mean fold* 8,6737, tetapi kesalahan ekstrem bertambah. Tidak mengganti baseline.

A.2 Ringkasan EXP-008 sampai EXP-014

EXP-008 Boosting sebagai alternatif. CatBoost 8,8470; XGBoost 9,0767; HistGBM 9,0991 pada evaluasi ini. Belum melampaui EXP-004.

EXP-009 Subset fitur dan interaksi residual. Raw24 + lima interaksi menjadi 8,9659. Redundansi tidak otomatis merugikan; rekayasa ini ditolak.

EXP-010 Kalibrasi prediksi OOF. Linear sekitar 8,6805 dengan manfaat kecil dan belum meyakinkan. Kalibrasi lain memburuk; tidak ada promosi.

EXP-011 Tail guard pada jalur anggota. Catatan anggota: CV 8,5690; publik sekitar 8,6645. Perbaikan lokal tidak diterjemahkan ke papan peringkat publik.

EXP-012 Guarded cutoff. Catatan anggota: CV 8,5786. Tidak diajukan sebagai pengganti; tidak ada skor publik terverifikasi.

EXP-013 Multi-*seed ExtraTrees*. Catatan anggota: CV 8,6961; publik sekitar 8,5341. Variasi *seed* belum memberi peningkatan cukup.

EXP-014 Raw24 ditambah PCA12. Catatan anggota: CV 8,5744; publik sekitar 8,4787. Mendukung pengujian representasi PCA lanjutan.

A.3 Ringkasan EXP-015 sampai EXP-021

EXP-015 *ExtraTrees* 400 dan PCA12. max_features 18; catatan CV 8,4624; publik 8,4377751817. Perbaikan pada jalur anggota.

EXP-016 PLS empat komponen. Catatan CV 8,6100. Tidak memberi manfaat cukup. PLS bukan kebocoran bila dipasang hanya pada *train fold*.

EXP-017 PCA16 dan PCA24. Catatan CV di atas 8,55. Penambahan komponen tidak membantu konfigurasi ini; bukan bukti seluruh komponen tambahan tidak informatif.

EXP-018 Model residual Ridge dan *ExtraTrees*. Catatan CV 8,3179; publik sekitar 8,6925. Penurunan CV tidak didukung hasil publik.

EXP-019 Quantile dan denoised PCA. Catatan CV di atas 8,5. Tidak dipromosikan; manfaat transformasi tidak konsisten.

EXP-020 Yeo–Johnson dan eksplorasi KMeans. Catatan CV Yeo–Johnson 8,4760. Eksplorasi jarak cluster diteruskan pada EXP-021.

EXP-021 Raw24 + PCA12 + jarak KMeans. ET400, max_features 22. Audit *mean fold* 8,4644; catatan anggota 8,4480 memakai konteks berbeda. Publik 8,2695099413.

A.4 Ringkasan EXP-022 sampai EXP-028

EXP-022 Ablasi komponen EXP-021. Raw24 + PCA12 mencapai *mean fold* 8,4427. KMeans tidak memberi keuntungan tambahan yang cukup; *pipeline* disederhanakan.

EXP-023 Kernel dan blend. Kernel mean 8,1797, publik 9,7606; blend mean 8,1011, publik 9,2409. Tidak dipertahankan sebagai kandidat publik.

EXP-024 Hipotesis dari advanced EDA. Seleksi komponen minor C2 sekitar 8,5202; C1 sekitar 8,4419. Tidak ada peningkatan stabil; baseline dipertahankan.

EXP-025 Submission raw24 + PCA12. ET max_features 22; *mean fold* 8,4427; *averaged OOF* 8,4745; publik 8,2578077455. Resep sederhana dipertahankan.

EXP-026 Mengurangi PCA menjadi enam. *Mean fold* 8,6669; alternatif max_features 18 sekitar 8,6411. Ambang variasi 95% tidak cukup sebagai alasan pengurangan.

EXP-027 TabPFN v2 raw24. *Seed* 42 *mean fold* 7,638113, lebih baik pada 28 dari 30 *fold* dibandingkan ET 8,4427. Pergeseran keluarga model diterima.

EXP-028 Konfirmasi *seed* TabPFN. *Seed* 42, 17, 2026 memberi mean sekitar 7,5493–7,6381. Publik *seed* 42 sebesar 8,1787092844. Komponen ansambel disiapkan.

A.5 Ringkasan EXP-029 sampai EXP-035

EXP-029 Rekonstruksi OOF dan audit PCA. Menghasilkan artefak *raw* tiga *seed* dan dua varian PCA yang sejajar. Cabang H scaled pooled 7,714311. Fokus keterlacakan, bukan skor publik baru.

EXP-030 Multi-*seed* cabang PCA. P3 pooled 7,732440 versus T3 7,683114. Blend multi-*seed* PCA memburuk sekitar 0,010176 terhadap pembanding. Tidak dipromosikan.

EXP-031 Submission rata-rata T3. Publik 8,1290159832. Mendokumentasikan manfaat penggabungan *raw* dan mempersiapkan pembanding untuk cabang PCA.

EXP-032 Blend T3 dan PCA scaled. Publik 8,0708363938. Menjadi baseline pengembangan; bukan berkas identik dengan FINAL anggota tim.

EXP-033 *RobustScaler* sebelum PCA. *Mean fold* sekitar 7,5570 versus 7,5893, tetapi satu *repeat* memburuk 0,037637. Gagal batas stabilitas; EDA terarah dilakukan.

EXP-034 Blend tetap Standard dan Robust. Tahap A mean Δ −0,021207; tahap B pooled Δ −0,020826. Publik 8,0704199627. Kandidat lokal, belum terbaik publik.

EXP-035 Audit PCA tanpa *scaling*. Tidak ada *fit* baru; *cache* yang cocok dipakai ulang. Pooled Δ −0,003116, 15 menang / 15 kalah, MAE sedikit memburuk. Tidak dipromosikan.

A.6 Percobaan paralel dan bukti tambahan

Catatan anggota kedua menguji kombinasi *ExtraTrees*, kernel, dan spline. Versi v2 memakai ET500 dan kernel 50:50; v2.5 memakai bobot 50:40:10 dengan spline; v3 memakai bobot 37,5:62,5. Catatan menyebut evaluasi hingga 90–120 *fold* dan perbaikan lokal kecil, tetapi skor publik sekitar 8,7–8,9 tidak mendukung promosi. Angka tersebut merupakan ringkasan catatan anggota, bukan evaluasi berpasangan terhadap artefak EXP-034 (arsip anggota, Lampiran C).

Percobaan hybrid 75% prediksi EXP-021 dan 25% komponen lain dilaporkan sekitar 8,33 pada papan peringkat publik. Tim juga melaporkan submission_A_INCUMBENT_T3_TA12_50 sebesar 8,0684559041 dan submission_abdul5 sebesar 8,0691991105. Resep exact kedua berkas tersebut tidak dipakai sebagai dasar klaim keunggulan dalam laporan karena keterlacakan kode pembuatnya belum setara dengan FINAL dan C809.

Survei keluarga model pada catatan anggota mencakup Ridge atau Lasso, KNN, LightGBM, XGBoost, CatBoost, dan *ExtraTrees*. Karena *preprocessing* serta protokol bervariasi, seluruh angka survei tidak digabung sebagai peringkat model yang setara. Kontribusinya adalah mengarahkan pencarian ke keluarga model yang lebih menjanjikan, lalu menjalankan perbandingan terkendali pada jalur eksperimen utama.

Audit metode dalam laporan ini berfokus pada pipeline FINAL, yang menggunakan fitur resmi tanpa record_id atau posisi baris sebagai masukan model. Submission yang dokumentasi metodenya belum lengkap tidak digunakan sebagai bukti keunggulan model. Kesimpulan audit dibatasi pada artefak yang telah diperiksa.

Terakhir, beberapa narasi historis pada catatan tim terlalu kuat, misalnya menyebut hasil yang tidak signifikan sebagai bukti “sepenuhnya acak” atau menganggap semua komponen dengan variasi kecil sebagai noise. Laporan ini membatasi kesimpulan pada pengujian yang benar-benar dilakukan. Penolakan kandidat berarti bukti untuk promosi belum cukup, bukan pembuktian matematis bahwa kandidat tidak pernah dapat membantu.

Catatan status tim: competition_rules.md menyebut 1–3 peserta. Tim mengonfirmasi susunan empat anggota telah disetujui dan lokasi tanda tangan Malang. Bukti pendaftaran atau pengecualian tertulis belum ditemukan dalam folder yang diaudit; status administratif ini belum dapat diverifikasi secara independen. Empat nama dipertahankan sesuai konfirmasi tim.

LAMPIRAN B IDENTITAS ARTEFAK DAN REPRODUKSI

B.1 Identitas berkas publik terbaik

Berkas tersedia: submission_T3_TA12_50_FINAL.csv, 96 prediksi dengan record_id unik dan sesuai *test*. Skor publik 8,0391335665 adalah hasil yang dilaporkan tim. Kode ditelusuri ke sel pembuat FINAL pada fik-fair gabung.ipynb (execution_count 15). Rata-rata prediksi 50,3900225711; minimum 34,2660471845; maksimum 90,7751175673. Nilai ringkas tersebut dan contoh keluaran yang ditampilkan cocok dengan berkas; seluruh hasil *rerun* belum terbukti cocok.

SHA256 FINAL:
863f6210025014f57ebefddbd4c7686508daebb797979fbb69f5405183aba977

SHA256 C809 dan FINAL (1):
172fdd2b69ebd899e8579bcc75f640d454c0ce01da465436976b1e15ff485030

SHA256 checkpoint model yang dicatat dalam audit:
2ab5a07d5c41dfe6db9aa7ae106fc6de898326c2765be66505a07e2868c10736

B.2 Informasi yang harus dipertahankan

Reproduksi memerlukan *train* dan *test* resmi, urutan kolom fitur, konfigurasi empat model, *checkpoint*, versi dependency, jenis perangkat, input DataFrame atau array, *preprocessing* setiap cabang, serta bobot prediksi. record_id hanya dipakai untuk penyelarasan keluaran. Memakai *seed* yang sama tanpa menjaga unsur lain belum menjamin keluaran byte-identik. Untuk FINAL, cabang PCA tidak memakai *scaler*, n_components 12, *solver* auto, *whitening* False; cabang mentah berupa DataFrame. Model dibuat dengan *checkpoint* v2, float32, n_estimators 8, n_preprocessing_jobs 1, dan *seed* 42/17/2026 untuk *raw* serta 42 untuk PCA. Bobot akhir 1/6, 1/6, 1/6, 1/2. *StandardScaler* + *solver* full pada skrip fikfair_T3_TA12_50_FINAL.py adalah resep scaled yang ditelusuri pada EXP-032, bukan konfigurasi identik berkas FINAL.

Validasi menyimpan pasangan record_id, indeks *repeat*, indeks *fold*, target, dan prediksi. *Cache* juga harus menyertakan identitas konfigurasi dan hash pembagian. *Rerun* diperlukan bila data, split, *preprocessing*, model, atau *checkpoint* berubah; tidak diperlukan hanya untuk membaca ulang metrik dari prediksi yang telah tersimpan dan cocok.

B.3 Pemisahan status hasil

FINAL adalah acuan publik terbaik yang dilaporkan; EXP-032 adalah baseline pengembangan dengan komponen tersimpan; EXP-034 adalah kandidat lokal pada pembagian baru. Audit berkas dan resep tidak sama dengan reproduksi eksekusi. Tidak ada klaim bahwa CV CPU identik dengan *pipeline* GPU pembuat FINAL atau bahwa *private* score telah diketahui.

B.4 Tingkat verifikasi dan rekonsiliasi catatan

Tingkat 1 — Identitas berkas (terverifikasi): hash FINAL berbeda dari C809; C809 dan FINAL (1) identik byte demi byte. Rata-rata selisih absolut C809 terhadap FINAL adalah 0,1047067 dan maksimum 0,9750493. Kecocokan nama atau korelasi tinggi tidak membuktikan kesamaan keluaran.

Tingkat 2 — Resep dan bukti keluaran tersimpan (tertelusuri): sel pembuat FINAL menyimpan konfigurasi, checksum *checkpoint*, jumlah prediksi, statistik ringkas, serta contoh baris. Bukti ini mendukung keterlacakan, tetapi bukan verifikasi ulang semua 96 prediksi. PROJECT_CONTEXT dan bagian historis registry masih memuat status lama FINAL belum tersedia; keberadaan fisik CSV dan notebook mengoreksi status ketersediaan tersebut tanpa menaikkan klaim menjadi reproduksi identik.

Tingkat 3 — Reproduksi eksekusi FINAL (belum terbukti): tidak dilakukan *rerun* dalam penyusunan laporan. CSV EXP-032 berbeda dari FINAL, dengan rata-rata selisih absolut 0,1258351 dan maksimum 1,2638761. Perakitan komponen EXP-032 cocok dengan CSV-nya hingga $1{,}42 \times 10^{-14}$, tetapi hanya memverifikasi aritmetika dari *cache*, bukan hasil *fit* ulang.

SHA256 CSV EXP-032: 22b4dd57d279e9ab60dd63ce35c6254c12315ff6641615c46e81e962231191f8

Lingkungan sumber FINAL: Kaggle GPU, Python 3.13.15, PyTorch 2.11.0+cu128, scikit-learn 1.6.1, TabPFN 9.1.0. Lingkungan OOF lokal: CPU, Python 3.11.8, PyTorch 2.12.1+cpu, scikit-learn 1.8.0, TabPFN 9.1.0. v2 adalah versi model, sedangkan 9.1.0 adalah versi paket.

Urutan demonstrasi: siapkan data dan *checkpoint* resmi; gunakan urutan feature_01–feature_24; pilih sel pembuat FINAL, bukan sel C809 atau skrip scaled; jalankan empat komponen lalu gabungkan bobot tetap; validasi 96 ID unik dan dua kolom; simpan CSV, prediksi komponen, konfigurasi, checksum, dan lingkungan. Langkah ini merupakan petunjuk reproduksi, bukan klaim bahwa *rerun* telah dilakukan.

LAMPIRAN C SUMBER BUKTI DAN CATATAN VERIFIKASI ANGKA

Tabel C.1 menunjukkan sumber utama untuk setiap kelompok temuan dalam laporan.

Tabel C.1 Sumber bukti untuk setiap kelompok temuan

Temuan	Sumber utama
Integritas dan distribusi	train.csv, test.csv; tabel dan gambar ADVANCED_EDA_001, *run* 20261002_173918
Korelasi dan PCA	table_05_strongly_correlated_pairs.csv; table_07_pca_explained_variance.csv; EXP-026
Perbandingan *train* dan *test*	table_22_train_test_distribution_comparison.csv; koreksi BH atas 24 *p-value*
Kalibrasi T3	EXP-030_CALIBRATION_FEASIBILITY_REVIEW; tabel kuartil *averaged* dan per *repeat*
Stabilitas RobustScaler	POST_EXP033_TARGETED_EDA_REPORT beserta addendum; EXP-033 dan EXP-034
Hasil akhir dan *provenance*	EXP-035_findings, metrics.json, run_manifest.json; fik-fair gabung.ipynb
Riwayat pengambilan keputusan	EXPERIMENT_HISTORY; registry; laporan EXP-001–035; catatan anggota

Catatan verifikasi angka. Laporan ini memakai rentang target resmi 32,5864–100,4400; 43 pasangan Pearson kuat (bukan 50, yang merupakan hitungan Pearson atau Spearman); PC6 sebesar 95,59% dan PC12 sebesar 99,20% pada tabel EDA; sembilan hasil KS tanpa koreksi yang tidak signifikan setelah koreksi BH pada ambang 0,05; serta validasi *development* C809 yang tidak disamakan dengan konfirmasi yang tidak terjalankan.

Perhitungan ulang laporan dibatasi pada audit berkas, statistik deskriptif, visualisasi tabel tersimpan, dan metrik prediksi yang sudah ada. Tidak ada pelatihan model, eksperimen baru, submission baru, perubahan kode/data sumber, atau pengambilan label *test*. Rincian transformasi rahasia panitia dan batas minimum RMSE mutlak tidak diklaim.

LAMPIRAN D EDA FITUR DAN METRIK TERSIMPAN

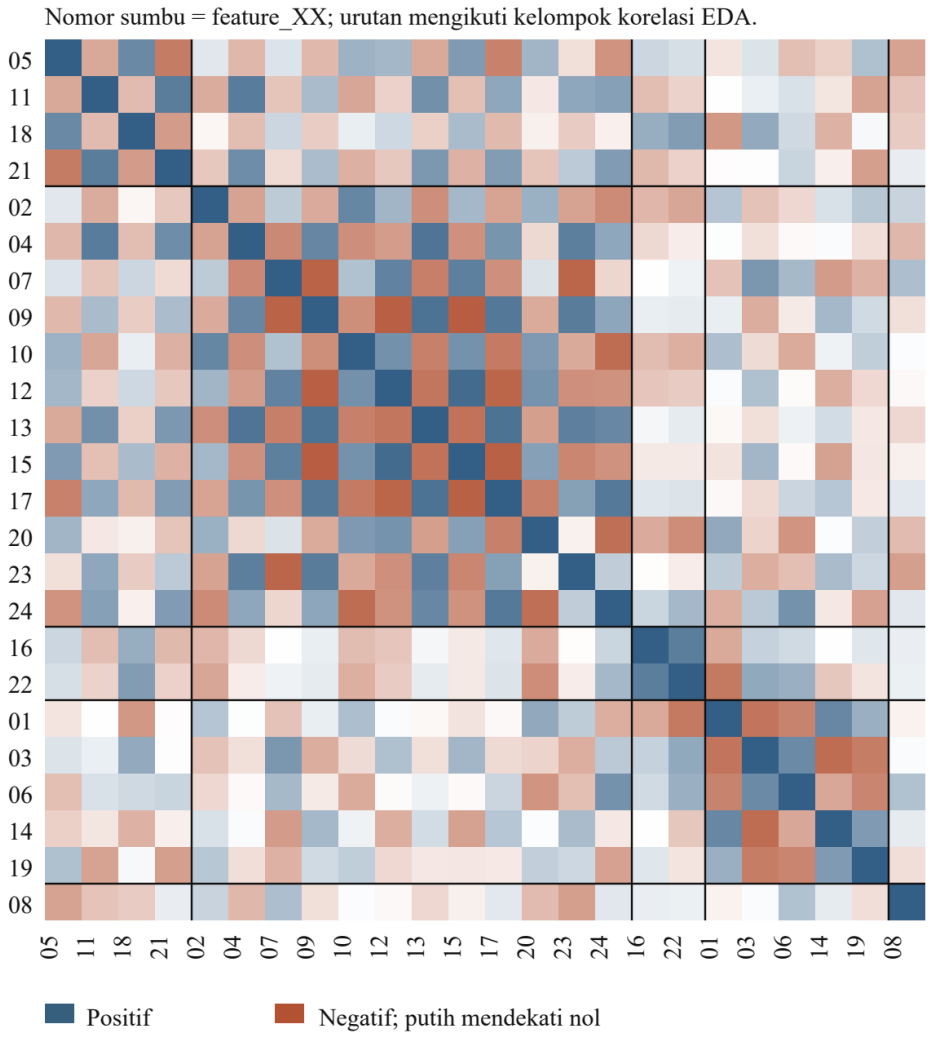
D.1 Statistik deskriptif 24 fitur

Tabel D.1 Statistik fitur pada train (tabel EDA 02)

Fitur	Mean	SD	Min	Max	Skew
01	-0,0365	0,9819	-2,1575	3,1195	0,2371
02	-0,0606	0,9765	-4,0276	2,9706	0,2019
03	0,0119	0,9728	-3,1431	2,6172	0,0269
04	0,0503	1,0007	-2,9938	2,0950	-0,7276
05	-0,0182	1,0153	-2,2278	3,4411	0,5760
06	0,0142	0,9749	-3,0816	2,0585	-0,7303
07	-0,0091	1,0095	-2,4618	2,8482	0,5529
08	-0,0022	1,0111	-3,9913	2,2732	-0,8905
09	0,0352	1,0019	-2,5167	2,7085	-0,4137
10	-0,0616	1,0040	-2,2046	2,4543	-0,0604
11	0,0330	1,0094	-2,7757	2,4511	-0,7034
12	-0,0299	0,9898	-2,4008	2,8946	0,8187
13	0,0337	1,0034	-2,6700	2,4155	-0,2562
14	-0,0423	0,9879	-3,5739	2,5732	-0,8762
15	-0,0212	1,0093	-2,5076	2,8534	0,6881
16	-0,0022	0,9893	-2,9258	3,1675	-0,2103
17	0,0268	0,9964	-2,9002	2,6852	-0,3711
18	-0,0239	1,0083	-2,5006	3,3974	0,4774
19	-0,0145	0,9920	-2,5321	2,5475	0,1169
20	-0,0232	0,9714	-2,5423	2,9145	0,4936
21	0,0447	0,9826	-2,7600	2,1853	-0,4665
22	0,0269	0,9910	-2,8447	3,0184	-0,5795
23	0,0343	1,0195	-3,0839	2,2448	-0,5809
24	0,0319	0,9890	-2,5113	2,9879	0,0978

D.2 Korelasi dan kelompok variabel

Statistik Tabel D.1 berasal dari table_02_feature_summary.csv pada EDA run 20261002_173918. SD adalah simpangan baku sampel dan *skewness* mengikuti estimator tabel sumber; seluruh fitur memiliki 382 nilai unik. Gambar 7 memakai kelompok variabel dari table_06_feature_clusters.csv untuk memperlihatkan redundansi. Warna menunjukkan arah dan besar korelasi; putih mendekati nol. Kelompok variabel ini bukan segmen observasi atau wilayah.



Gambar 7 Matriks korelasi Pearson 24 fitur, diurutkan menurut kelompok EDA

Kelompok 1: 05, 11, 18, 21. Kelompok 2: 02, 04, 07, 09, 10, 12, 13, 15, 17, 20, 23, 24. Kelompok 3: 16, 22. Kelompok 4: 01, 03, 06, 14, 19. Kelompok 5: 08. Nomor merujuk feature_XX, bukan identitas record.

D.2.1 Korelasi seluruh fitur dengan target

Sumber: table_09_feature_target_correlations.csv, EDA run 20261002_173918. Korelasi adalah asosiasi marginal, bukan *importance* atau bukti kausal.

Tabel D.2 Korelasi fitur dengan ACS

Fitur	Pearson r	Spearman ρ
feature_01	0,0143	0,0369
feature_02	-0,0541	-0,1075
feature_03	-0,2594	-0,2679
feature_04	0,2050	0,2547
feature_05	-0,1789	-0,1787
feature_06	0,0127	-0,0554
feature_07	-0,3316	-0,3431
feature_08	0,0418	0,0222
feature_09	0,3911	0,4199
feature_10	-0,2082	-0,2508
feature_11	0,0763	0,1130
feature_12	-0,3716	-0,3824
feature_13	0,3476	0,3892
feature_14	0,2136	0,1835
feature_15	-0,3756	-0,3891
feature_16	0,0476	0,0930
feature_17	0,3518	0,3899
feature_18	-0,0590	-0,0229
feature_19	0,1880	0,2134
feature_20	-0,2417	-0,2373
feature_21	0,1210	0,1167
feature_22	0,0236	0,0227
feature_23	0,2482	0,2984
feature_24	0,2260	0,2905

D.3 RMSE, MAE, dan R^2 dari averaged OOF

Metrik dihitung ulang secara deskriptif dari experiments/EXP-030/oof_predictions_averaged.csv, dengan 382 record unik yang targetnya cocok dengan *train*. Tiga prediksi OOF per record telah dirata-ratakan oleh artefak sumber. Perhitungan ini tidak memakai label *test* dan tidak melatih ulang model. R^2 memakai jumlah kuadrat penyimpangan target terhadap mean 382 target tersebut.

Tabel D.3 Metrik averaged OOF dari prediksi tersimpan

Model	RMSE	MAE	R^2
Raw seed 42	7,653869	5,241130	0,647374
T3 raw	7,612731	5,220504	0,651154
P42 scaled	7,637281	5,177808	0,648900
P3 scaled	7,659195	5,188220	0,646883
50% T3 + 50% P42	7,607629	5,186351	0,651621
50% T3 + 50% P3	7,618453	5,192844	0,650629

R^2 hanya berlaku untuk keluaran *averaged OOF* yang disebutkan; nilai ini bukan R^2 publik atau *private*. Tidak ada label *test* untuk menghitung MAE atau R^2 leaderboard. Baseline empiris yang terdokumentasi adalah *Random Forest* (EXP-001); laporan tidak menyatakan bahwa baseline_mean atau interval bootstrap yang diminta dalam review sudah diuji.

Ketidakpastian keputusan diperiksa melalui selisih *fold*/*repeat* dan pembagian baru yang sudah ada. Dependensi antarfold serta banyaknya seleksi adaptif tetap membatasi inferensi. Grafik residual juga tidak dijadikan dasar untuk mengklaim kalibrasi mustahil atau seluruh kesalahan merupakan noise.

LAMPIRAN E STATISTIK TARGET DAN DEFINISI ESTIMATOR

Nama resmi target pada Case Release adalah Anonymous Competition Score (ACS). Statistik berikut diverifikasi dari *train*.csv (382 target); perhitungan deskriptif tidak mengubah *pipeline* atau membuat eksperimen baru. SD memakai n−1; kuantil memakai interpolasi linear. *Skewness* dan *excess kurtosis* berbasis momen tanpa koreksi bias.

Tabel E.1 Statistik deskriptif dan kuantil target ACS

Statistik	Nilai	Kuantil/statistik	Nilai
N	382	P01	33,2883
Mean	51,2040	P05	35,0077
SD	12,9060	P10	36,4051
Median	50,2565	P25	39,6886
IQR	20,4777	P75	60,1662
Min	32,5864	P90	66,0187
Max	100,4400	P95	73,2208
Rentang	67,8536	P99	88,7937
Skewness	0,7484	Excess kurtosis	0,5108

Skewness = m_3/m_2^(3/2); *excess kurtosis* = $m_4/m_2^2 - 3$, dengan m_k sebagai rata-rata (target − mean)^k. Estimator terkoreksi yang memakai pandas menghasilkan *skewness* 0,7514 dan *excess kurtosis* 0,5334. Perbedaan ini berasal dari definisi estimator, bukan perubahan data; laporan konsisten memakai nilai berbasis momen pada Tabel E.1.

286 dari 382 target (74,87%) berada pada atau di bawah P75. Lebar rentang bawah adalah 27,5798 poin dan rentang atas 40,2737 poin. RMSE memberi bobot kuadrat pada besar residual, bukan pada nilai target: kesalahan 10 poin berkontribusi 100 pada *squared error*, baik target rendah maupun tinggi. Klaim "*heavy tail*" dalam arti distribusi asimtotik tidak ditetapkan dari *skewness* atau kurtosis ini saja.